







INDUSTRIAL PRODUCTIVITY PREDICTION MODEL OF INDONESIA MEDIUM AND LARGE INDUSTRIES

Final Project Proposal Group 5 Data Science Bootcamp Shift Academy Batch 13















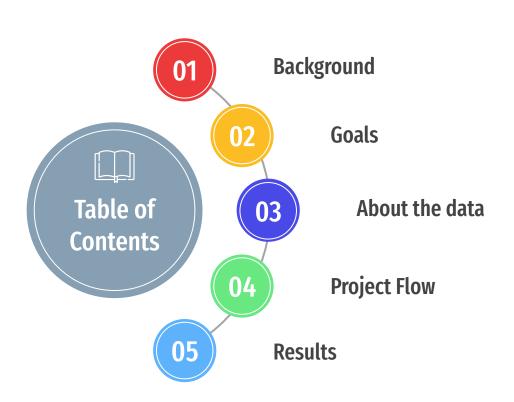


Coach: Faris Rizky Andika

TABLE OF CONTENTS



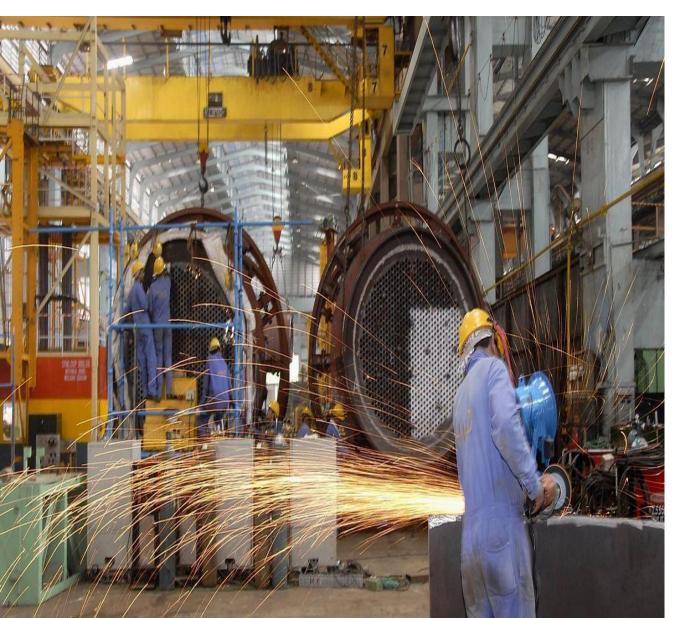






BACKGROUND





PROJECT: INDUSTRIAL PRODUCTIVITY PREDICTION MODEL OF INDONESIA MEDIUM AND LARGE INDUSTRIES

Kontribusi sektor industri terhadap perekonomian nasional mencapai 19% (BPS, 2021).

Maka dari itu, peran industri besar dan menengah cukup penting karena merupakan sektor formal yang menyerap tenaga kerja dalam menggerakkan perekonomian nasional.

Oleh sebab itu, pemerintah perlu memperhatikan kinerja industri besar dan menengah untuk mengambil kebijakan-kebijakan yang tepat dan relevan.







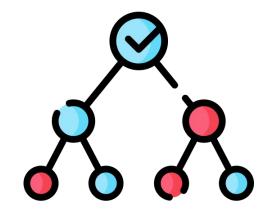
Untuk menentukan perusahaan yang memiliki produktivitas tinggi berdasarkan karakteristik individu perusahaan.

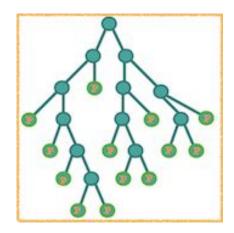
Berdasarkan informasi tersebut, pemerintah dapat menentukan kebijakan apa yang dapat diterapkan pada perusahaan yang memiliki produktivitas baik dan perusahaan yang tidak memiliki produktivitas yang baik.

Contoh: Insentif fiskal, Insentif non-fiskal.



Membangun **model classifier** yang memiliki kemampuan untuk memprediksi apakah suatu perusahaan memiliki produktivitas yang tinggi atau tidak.





ABOUT THE DATA





01

Sumber Dataset: BPS Published Data

https://drive.google.com/drive/folders/1a6uuL_ZUEAdJIdXEAfqU-vik0G 3cgyt7?usp=sharing

02

Jumlah Data

Jumlah sampel data sebanyak 27998 perusahaan (data training dan data test akan ditentukan kemudian)

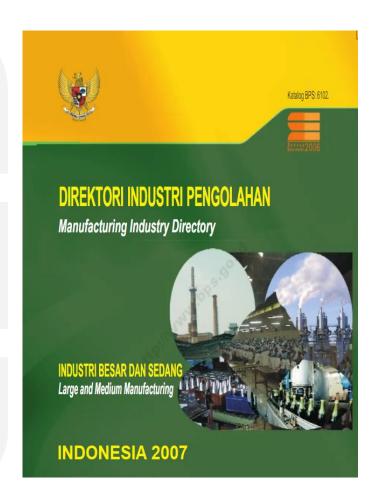
03

Jumlah Variabel

1 target

129 variabel (hanya variabel yang mempengaruhi produktifitas yang akan digunakan)

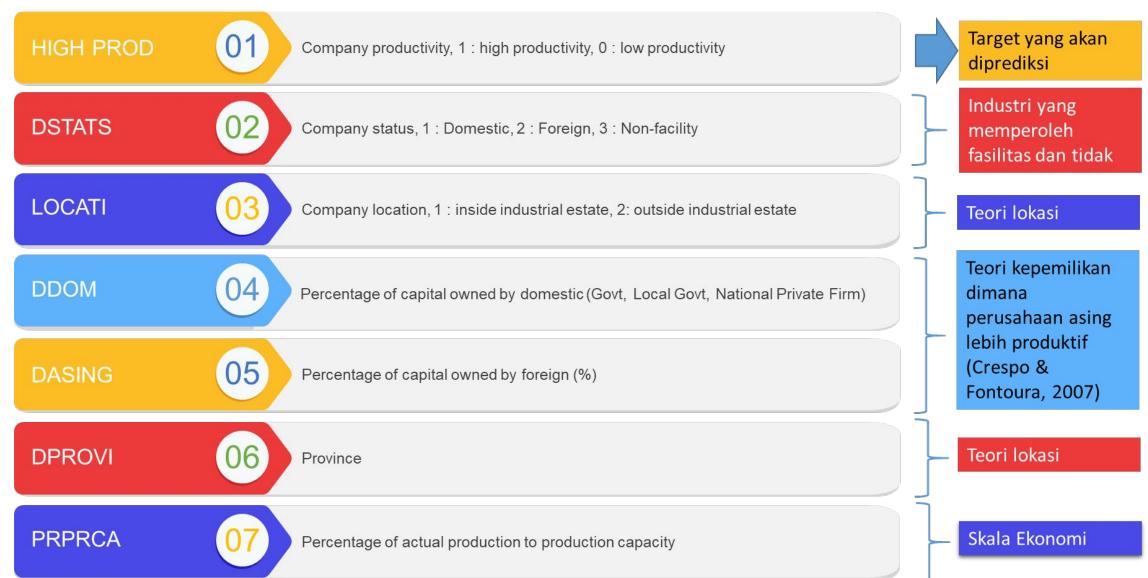
Tipe Data: bool, integer, float



ABOUT THE DATA (CONT'D)







ABOUT THE DATA (CONT'D)







Melihat jenis industri yang lebih produktif

Teori pertumbuhan sollow (Capital, Labor)

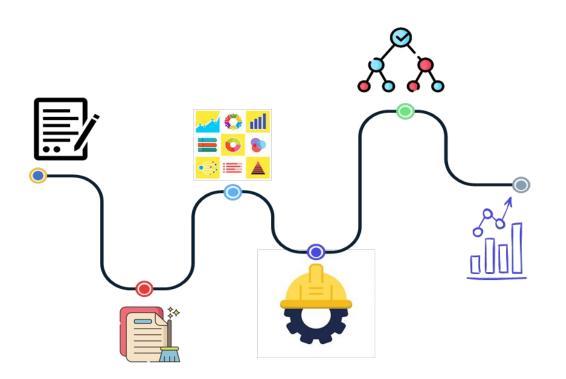
Dugaan kuat bahwa perusahaan yang ekspor lebih produktif

Modifikasi:
Perbandingan
jumlah pekerja di
produksi
dibandingkan total
jumlah pekerja

PROJECT FLOW STRATEGY







Topic & Dataset

 Determining which type of ML model to make (regression, classification, or clustering)

· Selecting an open source dataset

Creating a proposal presentation

Data Cleaning • Han

Reformatting data

· Handling null and missing values

Dropping data duplicates

· Handling outlier

EDA

• Creating data visualizations to gain insights

Featuring Engineering · Scaling features

• Encoding categorical features

Reducing data dimensions (PCA)

• Handling imbalance classes

· Selecting 'important' feature

Modelling

· Testing out various classification algorithms with training data

 Evaluating the performance metrics (recall, precision, f1 score, ROC/AUC

Model Evaluation

Predicting test data using model which has the best performance metrics

 If the result is not good enough, go back to feature engineering / modelling phase

Understanding Data









Look out our data





```
df1 = pd.read_csv('DATA_PROJECT.csv')
         df1.head()
Out[2]:
                        DKABUP07
                                   DSTATS07
                                              LOCATI07
                                                        JAN07 FEB07
                                                                       MAR07 APR07
                                                                                       MEI07
                                                                                             JUN07
                                                                                                     JUL07 AGS07
                                           2
          0
                    11
                              15.0
                                                   NaN
                                                           1.0
                                                                   1.0
                                                                           1.0
                                                                                  1.0
                                                                                         1.0
                                                                                                 1.0
                                                                                                        1.0
                                                                                                                1.0
                                                                                                                       1.0
                    11
                              15.0
                                                    1.0
                                                                           1.0
                                                                                  1.0
                                           3
                                                           1.0
                                                                   1.0
                                                                                         1.0
                                                                                                 1.0
                                                                                                        1.0
                                                                                                                1.0
                                                                                                                       1.0
          2
                    11
                              14.0
                                                                                 NaN
                                                                                        NaN
                                                                                                NaN
                                                   NaN
                                                          NaN
                                                                  NaN
                                                                          NaN
                                                                                                       NaN
                                                                                                               NaN
                                                                                                                      NaN
                                                                                                                              Na
                    11
                              14.0
                                                   NaN
                                                          NaN
                                                                                                                      NaN
                                                                  NaN
                                                                          NaN
                                                                                 NaN
                                                                                        NaN
                                                                                                NaN
                                                                                                       NaN
                                                                                                               NaN
                                                                                                                              Na
                    11
                              14.0
                                                   NaN
                                                           1.0
                                                                   1.0
                                                                           1.0
                                                                                  1.0
                                                                                         1.0
                                                                                                 1.0
                                                                                                        1.0
                                                                                                                1.0
                                                                                                                       1.0
          4
```

Data set tersebut terdiri dari 130 kolom dan 27.998 baris. Namun, hanya 14 kolom yang difilter untuk proses analisa.



Menambahkan kolom baru 'Percentage of Production Labor' ['PPL'] yang merupakan penambahan dari kolom 'LPMLTL07' (Male Production Labor) dan kolom 'LPWLTL07' (Female Production Labor)



```
In [53]: df['DDOM07'] = df['DPUSAT07']+df['DPEMDA07']+df['DDMSTK07']
```

Menambahkan kolom baru 'Percentage of Company Ownership by Domestic Parties' ['DDOMo7'] yang merupakan penambahan dari kolom 'DPUSATo7' (Percentage of Company Ownership by the Central Government). 'DPEMDAo7' (Percentage of Company Ownership by Regional Governments) dan 'DDMSTKo7' (Percentage Ownership of the Company by local Parties)

Filtering columns





```
In [52]: # filter kolom yang digunakan untuk analisa
           df = df1[['PSID','DPROVI07','DSTATS07', 'LOCATI07', 'DISIC507','DASING07','EKSPOR07','PRPRCA07',
                       'V1115', 'PPL', 'HIGH PROD']]
           df.head()
Out[52]:
                # kolom yang digunakan untuk proses cleansing data adalah sebanyak 12 kolom
                df = df.drop(columns=['DPUSAT07', 'DPEMDA07', 'DDMSTK07'])
                df.head()
                                                                                                     PPL HIGH PROD DDOM07
                                           LOCATI07
                                                    DISIC507
                                                              DASING07
                0 1761
                                               NaN
                                                        15141
                                                                  90.0
                                                                            NaN
                                                                                     50.0
                                                                                            0.0 0.616279
                                                                                                                      10.0
                1 1762
                              11
                                                1.0
                                                        15141
                                                                            2.0
                                                                                            0.0 0.099910
                                                                  90.0
                                                                                                                      10.0
                2 1763
                              11
                                                       15141
                                                                                            0.0 0.973684
                                               NaN
                                                                   0.0
                                                                            NaN
                                                                                                                     100.0
                3 1765
                              11
                                                        15141
                                               NaN
                                                                   0.0
                                                                            NaN-
                                                                                      0.0
                                                                                            0.0 0.750000
                                                                                                                     100.0
                4 1766
                              11
                                               NaN
                                                        15141
                                                                   0.0
                                                                            NaN
                                                                                            0.0 0.564516
                                                                                                                     100.0
```

Selanjutnya, kolom final adalah sebanyak 12 kolom yang akan diolah untuk proses cleansing data dengan kolom 'HIGH PROD' sebagai kolom target.

Filtering columns





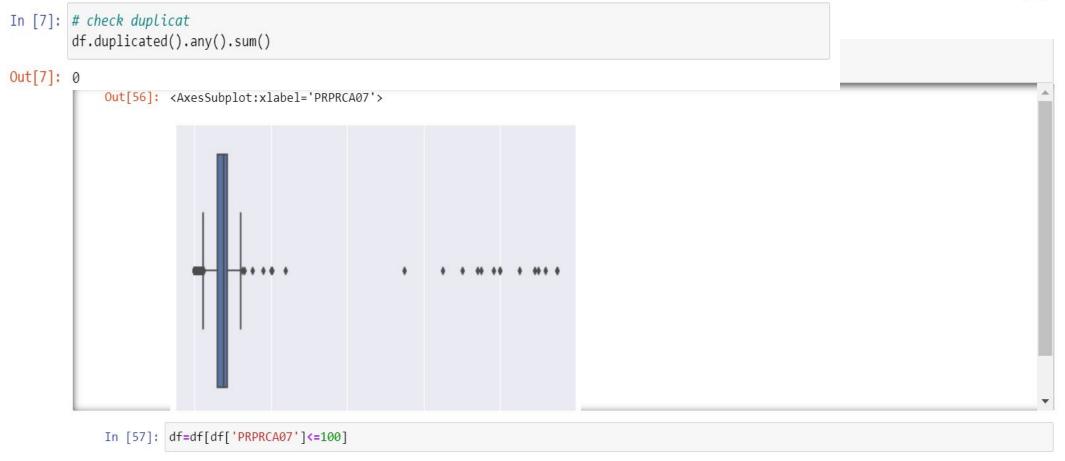
Kolom akhir yang digunakan:

No.	Nama Kolom	Arti Kolom
1	PSID	ID Perusahaan
2	DPROVI07	Wilayah dalam Provinsi
3	DSTATS	Status Perusahaan (1.Domestik, 2.Asing, 3.Non-Facility)
4	LOCATI	1: Di dalam kawasan industri. 2: Di luar kawasan industri
5	DISIC507	Klasifikasi Jenis Industri
6	DASING07	Persentase Kepemilikan Modal oleh Asing
7	DDOM07	Persentase Kepemilikan Modal oleh Lokal
8	EKSPOR07	Apakah ada produksi yang diekspor. 1:Ya, 2:Tidak
9	PRPRCA07	Persentasi dari realisasi produksi terhadap kapasitas terpasang
10	V1115	Jumlah total modal usaha
11	PPL	Persentase jumlah tenaga kerja produksi dibandingkan dengan keseluruhan tenaga kerja produksi
12	HIGH PROD	Produktifitas perusahaan (1:HIGH, 0: LOW)

EDA | Duplicated & Outlier







PRPRCA07 = Persentasi dari realisasi produksi terhadap kapasitas terpasang

EDA | Missing Value



```
In [67]: #menghapus modal di quantil 25
df=df[df['V1115']>=170000]
df['Modal Dalam Jutaan Rupiah'] = df['V1115']/1000000
```

Menghapus data di quantil 25 karena menurut kami itu data tersebut rancu. Lalu, menambahkan kolom baru 'Modal Dalam Jutaan Rupiah'.

EDA | Missing Value



```
In [63]: # check presentasi Missing value
            df.isnull().sum()/df.shape[0]*100
  Out[63]: PSID
                          0.000000
            DPROVI07
                          0.000000
            DSTATS07
                          0.000000
            LOCATI07
                         33.316330
            DISIC507
                          0.000000
            DASING07
                         0.000000
            EKSPOR07
                         33.396488
            PRPRCA07
                         14.147781
            V1115
                         47.784741
            PPI
                          0.000000
            HIGH PROD
                          0.000000
            DDOM07
                          0.003644
            dtype: float64
In [66]: df = df.dropna(axis=0)
```

Karena persentase missing value lebih dari 30%, maka kami memilih untuk menghapus seluruh data missing.

EDA | Data Type & Feature Transformation



```
  [25] df['HIGH PROD'].replace('0',0,inplace=True)
  df['HIGH PROD'].replace('1',1,inplace=True)
```

HIGH PROD = Produktifitas perusahaan (o: Low, 1:High,)

```
# Jawa = 1, luar jawa = 0

df1['DPROVI07'][(df1['DPROVI07']<30)]=0

df1['DPROVI07'][(df1['DPROVI07']>40)]=0

df1['DPROVI07'][(df1['DPROVI07']>30)&(df1['DPROVI07']<40)]=1</pre>
```

DPROVI07 = Lokasi perusahaan dalam provinsi (o. Luar Jawa, 1. Jawa)

EDA | Data Type & Feature Transformation



Dilakukan encode untuk variabel DISIC507 (Jenis Industri) agar mudah untuk mengetahui pengaruh dari jenis industri terhadap produktivitas perusahaan.

- 1 = industri agro
- 2 = industri tekstil
- 3 = industri pulp dan kertas
- 4 = industri percetakan
- 5 = industri pertambangan
- 6 = industri kimia
- 7 = industri logam dan mesin
- 8 = industri otomotif



```
/ [39] df1['LOCATI07'][(df1['LOCATI07']==1)]=1
    df1['LOCATI07'][(df1['LOCATI07']==2)]=0
```

LOCATIO7 = Lokasi perusahaan dalam dalam kawasan industri (o. Luar kawasan industri, 1. Dalam kawasan industri)

```
/ [40] df1['EKSPOR07'][(df1['EKSPOR07']==1)]=1
df1['EKSPOR07'][(df1['EKSPOR07']==2)]=0
```

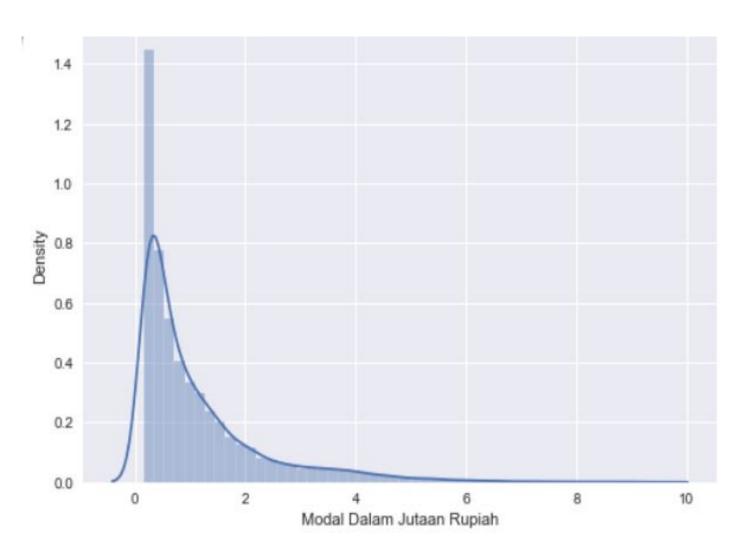
EKSPOR07 = Apakah ada produksi yang diekspor? (o. Tidak ada ekspor, 1. Ada sebagian atau Seluruh Produk yang diekspor)



Klik tautan di bawah untuk melihat visualisasi di tableau.

https://public.tableau.com/views/FinalProject2_16473593909990/Sheet11?:language=en-U S&:display_count=n&:origin=viz_share_link





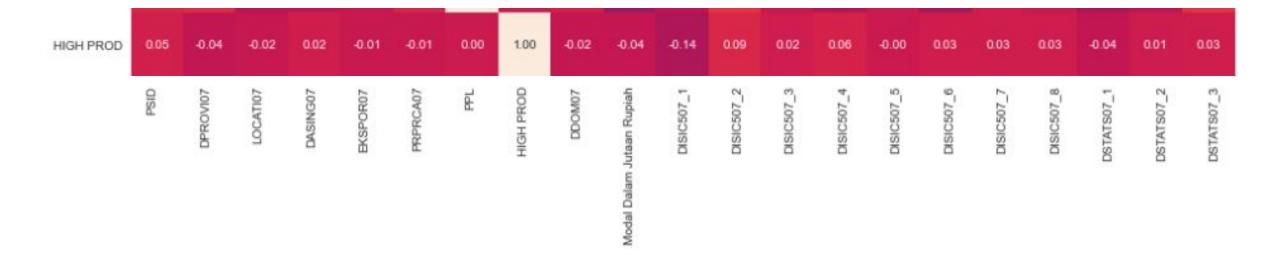
Variabel Modal ('Modal Dalam Jutaan Rupiah') distribusinya tidak normal (scew), sehingga digunakan scaling logaritma untuk mendapatkan hasil yang lebih baik.

df1['Modal Dalam Jutaan
Rupiah']=np.log1p(df1['Modal Dalam Jutaan
Rupiah'])

Correlation







Berdasarkan heatmap korelasi antara target dengan feature, dapat dilihat bahwa nilai korelasinya relatif kecil. Hal ini kemungkinan akan berpengaruh pada hasil pemodelan yang kurang memuaskan.

Modeling | Model preparation and Train Test Split



Kami membagi variabel X dan Y, lalu kami membagi lagi untuk data train dan data test.

```
In [301]: x = df1.drop(['HIGH PROD'],axis = 1)
y = df1['HIGH PROD']

In [302]: from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x,y, test_size = 0.2, random_state = 42)

In [303]: print(x_train.shape)
print(x_test.shape)
print(y_train.shape)
print(y_train.shape)
print(y_test.shape)

(7889, 18)
(1973, 18)
(7889,)
(1973,)
```

- Menghapus PSID dan DASING07
- 20% dataset untuk data test

Modeling | SMOTE & UNDERSAMPLING





SMOTE

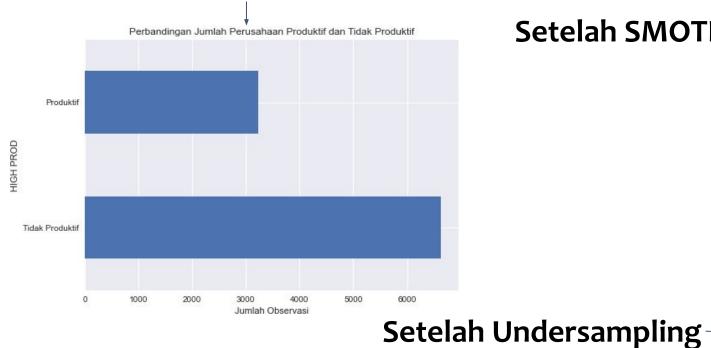
```
in [304]:
           from imblearn.over sampling import SMOTE
           from imblearn.under_sampling import RandomUnderSampler
 In [306]: smote = SMOTE(random_state=1)
           under_sampling = RandomUnderSampler(random_state=41)
 In [307]: y train.value counts()
 Out[307]: 0
               5302
               2587
           Name: HIGH PROD, dtype: int64
 In [308]: x_smote, y_smote = smote.fit_resample(x_train, y_train)
 In [309]: x_under, y_under = under_sampling.fit_resample(x_train, y_train)
 In [310]: y_smote.value_counts()
 Out[310]: 0
               5302
               5302
           Name: HIGH PROD, dtype: int64
 In [311]: y_under.value_counts()
 Out[311]: 0
               2587
               2587
           Name: HIGH PROD, dtype: int64
```

Modeling | SMOTE

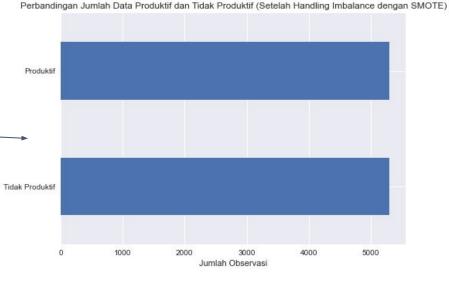




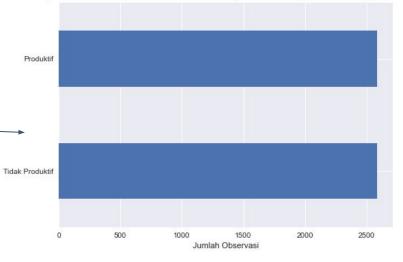












Modeling | Modeling





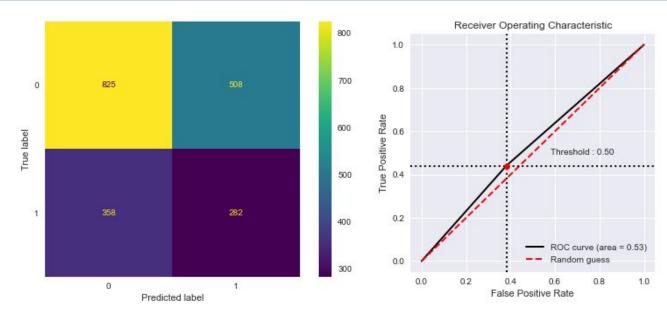
Modeling

```
In [314]: from sklearn.neighbors import KNeighborsClassifier
          from sklearn.svm import SVC
          from sklearn.ensemble import RandomForestClassifier
          from sklearn.linear model import LogisticRegression
          from sklearn.tree import DecisionTreeClassifier
          from sklearn.metrics import accuracy score
In [315]: knn = KNeighborsClassifier(n_neighbors = 99)
          rf = RandomForestClassifier(random state = 123)
          svm = SVC()
          lr = LogisticRegression(random state = 123)
          dt = DecisionTreeClassifier(random state = 123)
In [316]: models = [rf, svm, lr, knn, dt]
          for model in models:
              model.fit(x_train, y_train)
In [317]: ypred_rf = rf.predict(x_test)
          ypred svm = svm.predict(x test)
          ypred lr = lr.predict(x test)
          ypred knn = knn.predict(x test)
          ypred dt = dt.predict(x test)
```

Modeling | Modeling

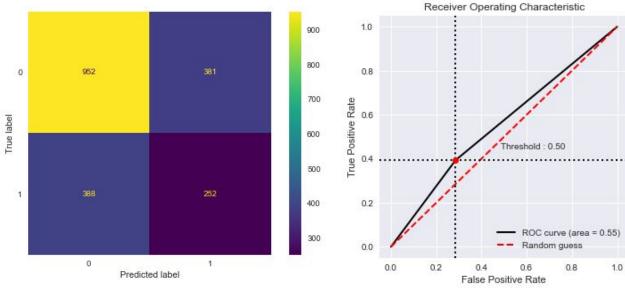






SMOTE Random Forest

SMOTE Decision Tree



Modeling | Evaluation





	LR Model Score (%)	DT Model Score (%)	RF Model Score (%)	SVM Model Score (%)	KNN Model Score (%)	LR Undersampling Model Score (%)	DT Undersampling Model Score (%)	RF Undersampling Model Score (%)	SVM Undersampling Model Score (%)	KNN Undersampling Model Score (%)
accuracy	67.663457	57.577293	65.129245	67.562088	67.359351	60.466295	56.107451	61.023822	63.507349	57.729346
recall	2.500000	34.531250	25.468750	0.000000	1.718750	45.937500	44.062500	39.375000	13.281250	52.968750
precision	53.333333	34.585290	43.582888	0.000000	42.307692	40.384615	35.696203	39.810427	34.000000	38.876147
roc_auc_score	50.724869	51.586705	54.819896	50.000000	50.296734	56.689680	52.976486	55.396427	50.451578	56.491877
f1_score	4.776119	34.558249	32.149901	0.000000	3.303303	42.982456	39.440559	39.591516	19.101124	44.841270

Undersampling Model Score (%)	LR Smote Model Score (%)	DT Smote Model Score (%)	RF Smote Model Score (%)	SVM Smote Model Score (%)	KNN Smote Model Score (%)
57.729346	60.466295	56.107451	61.023822	63.507349	57.729346
52.968750	45.937500	44.062500	39.375000	13.281250	52.968750
38.876147	40.384615	35.696203	39.810427	34.000000	38.876147
56.491877	56.689680	52.976486	55.396427	50.451578	56.491877
44.841270	42.982456	39.440559	39.591516	19.101124	44.841270

Modeling | Tuning



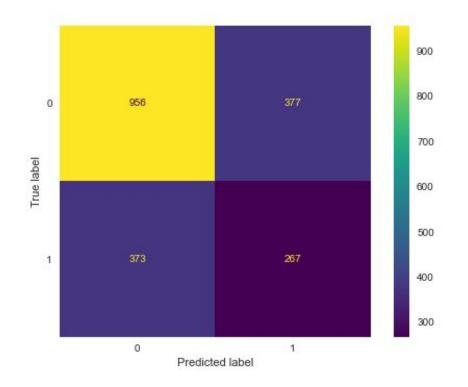


DE Emoto Model Coore	10/ \	DE Model	Coore After	Tuning/9/1
RF Smote Model Score	1701	Kr Model	Score Arter	Turring (70)

accuracy	61.023822	61.986822
recall	39.375000	41.718750
precision	39.810427	41.459627
roc_auc_score	55.396427	56.718340
f1_score	39.59 <mark>1</mark> 516	41.588785

Score Result

	precision	recall	f1-score	support	
0	0.72	0.72	0.72	1333	
1	0.41	0.42	0.42	640	
accuracy			0.62	1973	
macro avg	0.57	0.57	0.57	1973	
weighted avg	0.62	0.62	0.62	1973	



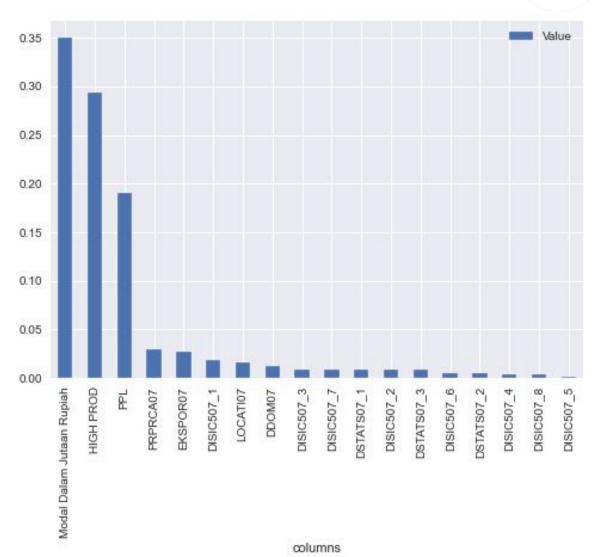
After tuning

Modeling | Feature Importance



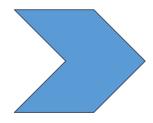


	columns	Importance	Value
0	LOCATI07	0.015740	0.015740
1	EKSPOR07	0.027530	0.027530
2	PRPRCA07	0.029426	0.029426
3	PPL	0.190406	0.190406
4	HIGH PROD	0.293566	0.293566
5	DDOM07	0.012788	0.012788
6	Modal Dalam Jutaan Rupiah	0.349665	0.349665
7	DISIC507_1	0.018907	0.018907
8	DISIC507_2	0.008347	0.008347
9	DISIC507_3	0.009140	0.009140
10	DISIC507_4	0.003919	0.003919
11	DISIC507_5	0.000913	0.000913
12	DISIC507_6	0.005278	0.005278
13	DISIC507_7	0.008848	0.008848
14	DISIC507_8	0.003443	0.003443
15	DSTATS07_1	0.008662	0.008662
16	DSTATS07_2	0.005138	0.005138
17	DSTATS07_3	0.008283	0.008283

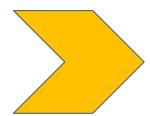


Future Plan

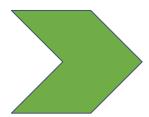




Menggunakan model lain seperti deep learning (jika memungkinkan) untuk mendapatkan hasil prediksi yang lebih baik



Mencari faktor lain yang berpengaruh terhadap produktivitas perusahaan



Melakukan merging data apabila terdapat data set lain yang memiliki ID perusahaan yang sama





